

Compressione dell'informazione / 28-04

$$V_x = \{x_1, \dots, x_n\} \quad |V_x| = n$$

$C(x)$ codifica binaria per x

$$C: V_x \rightarrow \{0,1\}^+ \\ \text{stringa binaria}$$

$$C^+: V_x^+ \rightarrow \{0,1\}^+$$

es. a, b, c, d $p(a) = \frac{1}{2}$ $p(b) = \frac{1}{4}$ $p(c) = p(d) = \frac{1}{8}$

$$C(a) = 1000$$

$$C(b) = 0100$$

$$C(c) = 0010$$

$$C(d) = 0001$$

\uparrow
4 simboli

\nwarrow
rappresentato con 2 simboli:

$$L_C(x) = 4 \quad \forall x \quad \text{lunghezza sequenze}$$

$$H(X) = \frac{1}{2} + \frac{1}{4} + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 6 = \frac{14}{8} = 1.75 \\ \cdot \log_2 2$$

Decifrabilità univoca

$$\forall x, y \in V_x^+ : x \neq y \rightarrow C^+(x) \neq C^+(y) \quad \text{iniettiva}$$

se 2 simboli diversi sono associate codifica diverse

C_1

$$C(a) = 1000$$

$$C(b) = 0100$$

$$C(c) = 0010$$

$$C(d) = 0001$$

poiché sono tutte della stessa lunghezza e sono diverse, allora sono univocamente decifrabili per qualsiasi parola comparsa

C_2

$$\frac{1}{2} C(a) = 1$$

$$C^+(ab) = C(a)C(b) = 10$$

ma univoc. dec.


$$\frac{1}{4} C(b) = 0$$

$$C^+(c) = 10$$

$$\frac{1}{8} C(c) = 10$$

$$\frac{1}{8} C(d) = 01$$

Istantaneità (regola del prefisso)



root
1000

la scansione di una codifica
è un albero binario
(con tante foglie non toccate)

Otengo "istantaneamente" la sequenza espressa
So quando finisco la sequenza

Univocità $\xrightarrow{?}$ Istantaneità 1) NO

Istantaneità $\xrightarrow{?}$ Univocità 2)

1)


a) 1 è univoca e non è istantanea perché ottenuto 1

b) 10 non so ancora se è b, se ho 10 non so ancora se

c) 100 ho c, " per d, devo attendere quello successivo

d) 1000

2) se posso costruire un albero a cui giungo alle foglie (conclusione
dei simboli) ho una definizione univoca



00 è identificata
in un solo modo

$$L(C, V_x) = \sum_{x \in V_x} p(x) \cdot L_c(x)$$

lunghezza attesa
di una codifica

mi aspetto

di utilizzare 2 bit

(< 2 perché non equivo) non scrivere
4 caratteri

$$L(C_1, V_x) = 4 \quad \text{perché sono tutte lunghe 4}$$

$$L(C_2, V_x) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 1 + \frac{1}{8} \cdot 2 + \frac{1}{8} \cdot 2 = \frac{5}{4} = 1,25 < H(x) = 1,75$$

||

$$C_3 \quad c(a) = 1 \quad L(C_3, V_x) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = \frac{14}{8} = 1,75$$

$$c(b) = 01$$

↳ perché se si scrive con un bit, la media delle lunghezze si ottiene

$$c(c) = 000$$

se ho tale lunghezza ottengo una compressione

$$c(d) = 001$$

più efficiente (risparmio dei bit, albero più corto)

$$x_1, \dots, x_{|V_x|} \quad L_1, \dots, L_{|V_x|}$$

La disuguaglianza di Kraft-McMillan dice che se univocamente
decodificabile allora è vera

$$\sum_{i=1}^{|V_x|} 2^{-L_i} \leq 1$$

$$= \sum_{i=1}^{|V_x|} \frac{1}{2^{L_i}} \leq 1$$

(e se nelle parentesi
allora \exists cod
univoc. ma non
è detto che lo
siano tutti)

se > 1 sto 'prevedendo', posso ottenere qualcosa di meglio come codifica
(L minore)

$$(A)^n = \left(\sum_i 2^{-L_i} \right)^n \quad \text{se } > 1 \text{ cresce, se } < \text{decresce}$$

$$= \sum_{i_1} \sum_{i_2} \dots \sum_{i_n} \underbrace{2^{-L_{i_1}} \cdot 2^{-L_{i_2}} \dots 2^{-L_{i_n}}}_{\text{in modulo}}$$

presumo $L_1 \leq L_2 \leq \dots \leq L_{|V_x|}$

$n L_1$ esp più piccolo

$n L_{|V_x|}$ " " grande

} in modulo

$$L = \sum_{L=nL_1}^{nL_m} 2^{-L} V_L \rightarrow \text{n° di stringhe di lunghezza } L$$

$$L_{i1} + L_{i2} + \dots + L_{in} = L$$

$$V_L \leq 2^L \rightarrow \text{max n° di stringhe generate}$$

$$\leq \sum_{L=nL_1}^{nL_m} 1 \leq nL_m$$

quindi $A^n \leq 1$ altrimenti non vale V_n e A^n crescerebbe più del termine lineare nL_m

1 0 0 0

0 1 0 0

0 0 1 0

0 0 0 1

$$\frac{1}{16} + \frac{1}{16} + \frac{1}{16} + \frac{1}{16} = \frac{1}{4} < 1 \quad \text{quindi non è equiprobabili}$$

1

0

1 0


0 1

$$\frac{1}{2} + \frac{1}{2} + \frac{1}{4} + \frac{1}{4} = 1.5 > 1 \quad \text{codifica non buona non univoca}$$

con 1, 2, 3, 3
unibresce


$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{8} = 1 \quad \text{codifica perfetta}$$

Immaginando ora da ogni vertice dividendo a metà il valore del padre
↳ "una quantità di unibresce"



ma allora nelle C, precedente $\frac{3}{4}$ di 'quantità' sprecate

- 1 —
- 2 +
- 3 + +
- 3 + T



de e' ends instantenee

1

10

101

100