

# Teoria dell' Inferenza / 13-05

## Principio di massima verosimiglianza

L'idea è come darviore l'informazione trasmessa dai dati  
es lancio moneta con risultati 1101110100111010111

$$n = 20$$

$$\frac{3}{10} \text{ freq } 0 \quad \frac{7}{10} \text{ freq } 1$$

(dedurre)  
posso inferire che la p di ottenere 1 è  $\frac{7}{10}$   
= dato da un'intuizione frequentista

$$p_0 = p(\text{testa}) = 1$$

1 cor un solo caso

$$1 - p_0 = p(\text{croce}) = 0$$

$p = 1$ , difficile  
determinare altrimenti

Posso determinare se dato una moneta "onesta", presta lo sia  
veramente  $\rightarrow$  inferisco delle conclusioni

$p_0$  voglio inferire, dedurre un valore  $\theta_0$  cor  $\theta \in \Theta$   
degli n dati

$$p \in [0, 1]$$

X utilizzare

es.

$$0 \ 0 \ 1 \ 0$$

valori di

$$p = 0,1 \ 0,2 \ 0,5 \ 0,9$$

Bernoulli

$$\text{calcolo } P_R(X | p) = P_R(x_1, x_2, x_3, x_4 | p)$$

↓  
cioè che ho  
↳ e' di X


non so da p ho utilizzato, assumiamo  $p(1) = 0,1$   $p(0) = 0,3$

$$P(\underbrace{0010}_{\text{indip.}} \mid p=0,1) = 0,3 \cdot 0,3 \cdot 0,1 \cdot 0,3 = 0,0729 \quad \text{probabilità della sequenza}$$

$$P_2(0010 \mid p=0,3) = 0,1 \cdot 0,1 \cdot 0,3 \cdot 0,1 = 0,0009$$

diremo che p è il parametro che massimizza  $P_n$   
e questo è detto massimo delle verosimiglianze

Possò garantire la sicurezza di quanto affermo, ma non che sia giusto o sbagliato



ovvero posso affermare quale valore  
di p determina un risultato più  
probabile e devo quindi si  
guadagnare di più e per il reale

$f_0(x) \rightarrow$  verosimiglianza  
le stringo

valore  
del  
parametro che  
lo genera

$$f_p(x) = p^x (1-p)^{1-x}$$

vor  
di Bernoulli:

$x_i \in X$  sono eventi  
INDEPENDENTI

$$x=1 \quad f_p(x=1) = p$$

$$x=0 \quad f_p(x=0) = 1-p$$



$$L(x_1, \dots, x_n | p) = \prod_{i=1}^n f_p(x_i)$$

preservano i massimi  
(non rischia di combaciare)

Applicando il logaritmo rende la funzione monotona:

$$\ln L = \sum_{i=1}^n \ln(p^{x_i} (1-p)^{1-x_i}) \quad \rightarrow \text{trasformo il prodotto in somme}$$

$$\frac{d \ln L}{dp} = 0 \quad \rightarrow \quad p_0 = \frac{1}{n} \sum x_i \quad \text{avere determinato } p \text{ sulla base}$$

annullo le derivate  
applica il principio di massima verosimiglianza  
rispetto a  $p$  su una base frequentista

della frequenza di  $x_i$   
(avere osservato il valore medio)

$$= \sum_{i=1}^n (x_i \ln p + (1-x_i) \ln (1-p))$$

$$\rightarrow = \sum_{i=1}^n \left( \frac{x_i}{p} - (1-x_i) \frac{1}{1-p} \right) = 0$$

$$\rightarrow \frac{1}{p} \sum_i x_i - \sum_i \frac{1}{1-p} + \sum_i \frac{x_i}{1-p} = 0$$

$$\rightarrow (1-p) \sum x_i - np + p \sum x_i = 0 \quad \rightarrow \hat{p} = \frac{\sum x_i}{n}$$

dove  $\hat{p}$  è una stima di  $p_0$  (perché è probabile ma non sicuro)

- 57, 112, 5 n° di taxi passati, p di vedere un taxi è maggiore di 1/2

si prende una distribuzione uniforme

$f_S(x)$  è ora una dist. uniforme e non bernoulliana

$$\frac{1}{S}$$

$$f_S(x) = \begin{cases} \frac{1}{S} & \text{se } 0 \leq x \leq S \quad (x \text{ è un taxi}) \\ 0 & \text{altrimenti} \end{cases}$$

dove  $S$  è il

parametro  $\Theta$ , da determinare

$$L(x_1, x_2, x_3 | S)$$

$2 = 0 \cdot 0 \cdot 0$  non è verosimile che vedo 2 taxi  
se ne vedo di più

$$L(57, 112, 5 | S_0) = 0 \cdot 0 \cdot \frac{1}{S_0}$$

$$L(57, 112, 5 | 1000) = \frac{1}{1000} \cdot \frac{1}{1000} \cdot \frac{1}{1000} = 10^{-9}$$

piccola, infatti è  
poco prob. di vedere 1000


che valore d'  $S$  per ottenere il max? 112

$$\text{quindi: } \hat{S} = x_{\max}$$

Sassiano



$$f_{\mu, \sigma^2}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$



Così  $\mu$  e  $\sigma^2$  che determinano il modo di versamento

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i \text{ infatti:}$$

$$\begin{aligned} \ln L &= \ln \left[ \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \prod_{i=1}^n e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} \right] \\ &= -\frac{1}{2} \ln (2\pi\sigma^2)^n - \sum_{i=1}^n \frac{(x_i-\mu)^2}{2\sigma^2} \end{aligned}$$

per via dell'esp.

$$\frac{\partial L}{\partial \mu} = 0 - \sum_{i=1}^n (x_i - \mu)^2 = 0$$

non dipende da  $\mu$

$$\rightarrow \sum x_i = n\mu \rightarrow \hat{\mu} = \frac{\sum x_i}{n}$$

dove la posta, ciò che non è  $\mu$  diverso una costante

ma ora voglio considerare anche  $\hat{\sigma}^2$

$$-\frac{1}{2} \ln (\pi \hat{\sigma}^2)^n - \sum_{i=1}^n \frac{(x_i - \hat{\mu})^2}{\hat{\sigma}^2}$$

so che in derivate  $\Rightarrow \mu$   
vole  $\hat{\mu}$

defin

$$\frac{\partial \ln L}{\partial \hat{\sigma}^2} \rightarrow -\frac{n}{2\hat{\sigma}^2} + \left[ \frac{1}{2} \sum_i (x_i - \hat{\mu})^2 \right] \frac{1}{\hat{\sigma}^4} = 0$$

$$= -1 + \frac{\sum (x_i - \hat{\mu})^2}{\hat{\sigma}^2} = 0 \rightarrow \hat{\sigma}^2 = \sum (x_i - \hat{\mu})^2$$

Ho trovato i migliori  $\hat{\mu}$  e  $\hat{\sigma}^2$  per cui la gaussiana mi produce i valori verosimiglianti a quelli dati

La media che faccio e' uno stimatore **corretto**, per fini "reali"  
sicuramente oscilla ma comunque ritorna a  $p_0$

Altamente lo stimatore e' **distorto** (bias), e' imprudente dire  
"sbagliato"

$$\mathbb{E} [\hat{p}] = p_0$$

il principio ci garantisce che lo stimatore  
oscilla fino al valore vero

13-05

Non stiamo parlando di probabilità →



l'area totale sotto la gaussiana  
non è  $= 1$

si osservano, su un numero alto d:  
frequenze, i parametri da meglio  
rappresentare le probabilità con un  
ottenuto un certo evento A

## Teorema di Bayes

2 persone su 1000 → 0,2%

prob. afflito dalla patologia

Così si dice di un test

probabilità che un soggetto

SENSIBILITÀ del 95%.

dalle patologie risulti  
positivo al test

SPECIFICITÀ del 98%.

probabilità che un individuo sans  
risulti negativo

Senza test,  $p(\text{malato}) = 0,2\%$ .

$P(\text{malato} | \text{positivo}) = ?$

$P(\text{positivo} | \text{malato}) = 0,95$

$P(\text{negativo} | \text{malato}) = 0,05$

$P(\text{positivo} | \text{sano}) = 0,01$

$$P(\text{negativo} \mid \text{sens}) \approx 0,33$$

Certo risultato positivo: con che p è malato?

VERSOGLIATA (valore più vicino allo zero)

$$P(\text{mal} \mid \text{pos}) = \frac{P(\text{pos} \mid \text{mal}) \cdot P(\text{mal})}{P(\text{pos})}$$

$$P(\text{pos}) = P(\text{pos} \mid \text{sens}) \cdot P(\text{sens}) + P(\text{pos} \mid \text{non mal}) \cdot P(\text{non mal})$$

$$P(\text{mal} \mid \text{pos}) = \frac{0,85 \cdot 0,002}{0,33 \cdot 0,002 + 0,01 \cdot (0,33)} = 1,6\%$$

Allora il 38,5% delle persone dichiarate pos non sono malate

(8 volte tante rispetto a essere malato senza test, ovvero 0,2%).

(inizio delle informazioni)

0000
A A B C

cassette con 4 monete, di tipo A, B, C

$$\left. \begin{array}{l} P(T|A) = \frac{1}{2} \\ P(T|B) = \frac{3}{5} \\ P(T|C) = \frac{8}{10} \end{array} \right\} \text{verso scommesse}$$

$$\begin{array}{l} P(A) = \frac{1}{2} \\ P(B) = \frac{1}{4} \\ P(C) = \frac{1}{4} \end{array}$$

Prese una moneta e così:  
infinito puoi dire ho preso

} più probabilmente  
A senza alcun tiro

1) Sappiamo che tirando la moneta c'è uscita testa?

→ scelgo la più probabile

2) se ottengo nuovamente testa?

→

$$P(A|T) + P(B|T) + P(C|T) = 1$$

p. e posteriori (osserva i C verificarsi di un evento, poi sceglie)

$$P(A|T) = \frac{P(T|A) \cdot p(A)}{P(T|A) \cdot p(A) + P(T|B) \cdot p(B) + P(T|C) \cdot p(C)}$$

per  $P(B|T)$  e  $P(C|T)$  il denominatore è lo stesso,  
quindi circa il **NORMIZIONE** più grande

H	priori	Verosimiglianza	p. posteriore normalizzata	normalizza e "aggiorno" a una priori	oppure Verosim. e ottengo la nuova scelta
A	0,5	$\frac{1}{2}$	0,25	0,4	x il 2° lancio (vedi sotto)
B	0,25	$\frac{3}{5}$	0,15	0,26	*
C	0,25	$\frac{3}{10}$	0,225	0,36	
	1		0,625	1	
	$\downarrow$		$\downarrow$		
	sceglie A		sceglie A		

Il frequentista lancia tante volte e conta chi è uscito maggiormente;  
il bayesiano osserva con la verosimiglianza e ripete

Lancia nuovamente la moneta e ottengo testa:

H	priori *	versosimiglianza	posteriori non normalizzate	normali: sono e "primo" o a una priori
A	0,4	$\frac{1}{2}$	$0,2$	modifico
B	0,25	$\frac{3}{5}$	0,166	
C	0,36	$\frac{8}{10}$	0,326	
1			$\neq 1$	1

dopo due testate  
scorriente su tipo C

se uscisse un'altra testata con le nuove p. e priori da quelle posteriori ma le versosimiglianze non e' piu' su TES.1  
ma su CROCE

indipendentemente  
dalla moneta

$$\begin{aligned}
 P(T_1) &= P(T_1 | A) \cdot P(A) + P(T_1 | B) \cdot P(B) + P(T_1 | C) \cdot P(C) \\
 &= \frac{1}{2} \cdot \frac{1}{2} + \frac{3}{5} \cdot \frac{1}{3} + \frac{8}{10} \cdot \frac{1}{3} = \frac{10+6+8}{10} = \frac{24}{10} = \frac{12}{5} = 0,625
 \end{aligned}$$

(effettivamente le monete sono più propense ad avere T,  $P(T_1 | \cdot) \geq \frac{1}{2}$ )

7250 (non importa se prima/secondo ...)

$$\begin{aligned}
 P(T_2 | T_1) &= P(T_2 | A) \cdot P(A | T_1) + \\
 &\quad P(T_2 | B) \cdot P(B | T_1) + \\
 &\quad P(T_2 | C) \cdot P(C | T_1)
 \end{aligned}$$

Secondo che ho avuto testa  
prima, osservo con quale p.  
ho scritto A, B, C

$$= 0,5 \cdot 0,4 + 0,6 \cdot 0,25 + 0,8 \cdot 0,36 = 0,668 \quad p \text{ una seconda testa}$$

## Relativamente alle Gaussiane

$$\hat{\mu} = \frac{\sum x_i}{n}$$

$$\hat{\sigma}^2 = \sum \frac{(\hat{\mu} - x_i)^2}{n}$$


dal punto di vista  
frequentista

Dal punto di vista bayesiano determina le stime avendo osservato  
qualcosa di precedente, dandone informazioni e priori

$$\hat{\mu}_{\text{post}}$$

$$\hat{\sigma}_{\text{post}}$$

verso che anche loro provengono  
da una gaussiana



tale per cui i parametri:

$$\mu_{PR} = \mu$$

$$\sigma_{PR}^2 = 1$$

avendo ora i dati 3, 1, 2, 4, 2, 7, 3, 4 come  $S$

Che quindi è traslato rispetto a quella reale (pregiudizio leggermente  
corroto)

Se applico il prodotto dei dati rispetto alle verosimiglianze ottengo una  
nuova gaussiana.

$\mu_0, \sigma_0^2$  sono veri e non noti

$\hat{\mu} \xrightarrow{\text{TENDE}} \mu_0$  in probabilità per  $n \rightarrow \infty$  || frequentista  
 $\hat{\sigma}^2 \xrightarrow{} \sigma_0^2 \frac{1}{n}$  .. .. ..

$$\mu_{\text{post}} = \frac{\sigma_0^2 \mu_{PR} + \sigma_{PR}^2 n \hat{\mu}}{\sigma_0^2 + n \sigma_{PR}^2}$$

la somma  
è 1

	μ <sub>PR</sub>		bayesiano
	σ <sub>PR</sub> <sup>2</sup>		

pregiudizio, fornito a priori

↓

principio:

se  $\mu_0$  è l'ipotesi che si ha tenendo conto del pregiudizio  $\delta_0^2$  per la media  $\mu$ , e  $\mu_{\text{post}}$  sono i dati effettivamente ottenuti, allora  $\delta_{\text{post}}^2 = \delta_0^2 + n \delta_{\text{PR}}^2$

$$\delta_{\text{post}}^2 = \frac{\delta_0^2 \delta_{\text{PR}}^2}{\delta_0^2 + n \delta_{\text{PR}}^2}$$

in accordo al frequentista  
per  $n$  grandi vince il  
giudizio a priori  
( $\delta_{\text{pri}}^2 \rightarrow \delta_{n/2}^2$ )

/ 20-05

Principio di max verosimiglianza

Principio di max probabilità a posteriori

$$P(A) = P(A|B)P(B) + P(A|\neg B)P(\neg B)$$